# Three-Layer View of Knowledge Corruption in LLM Unlearning

## 为什么要审计 forget set，而不是每次都 unlearn

Bo | `unlearning/`

Llama-3.1-8B-Instruct + GradAscent + WikiText-103 (HDBSCAN $\times$ 10)

# 一句话贡献

Unlearning 的副作用沿语义距离**三层衰减，但不归零**。

**L1 1.76× → L2 1.29× → L3 1.16×**

且 61.6 % 的「无关」样本 PPL 也被抬高。

*Llama-3.1-8B-Instruct · GradAscent · $n = 10$ forget sets.*

# 动机与定义

# 动机：一句话

换个 forget set，副作用能差 **1.7×**。

可每跑一个 unlearn 要数 GPU-hour。

能不能不 fine-tune，就预测副作用？

# 三层是什么：一张同心圆图

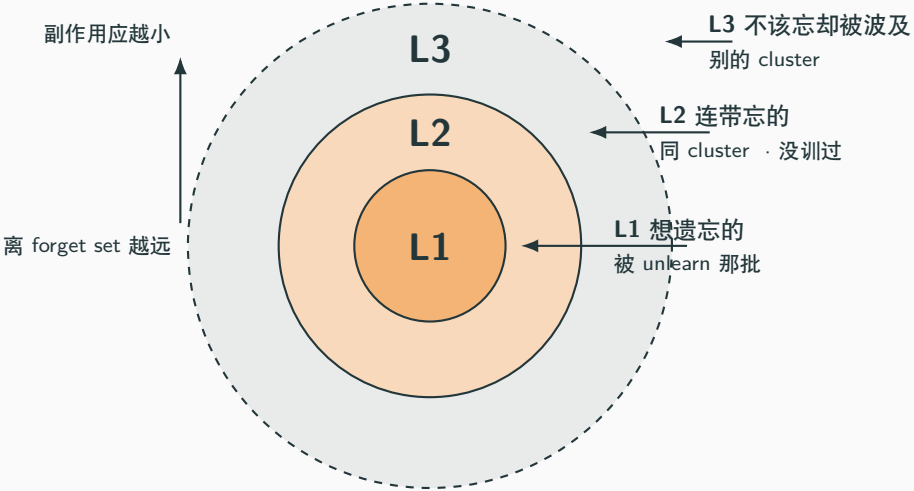

# 怎么量化：一个比值

$$r = \frac{\mathrm{PPL}_{\mathrm{unlearned}}}{\mathrm{PPL}_{\mathrm{base}}}$$

$r = 1.8 \Rightarrow$ **这条样本的 PPL 被抬高到 1.8 倍**。

每一层取几何均值 $\Rightarrow$ 得到 L1 / L2 / L3 的一个数。

# 数据怎么来：四步

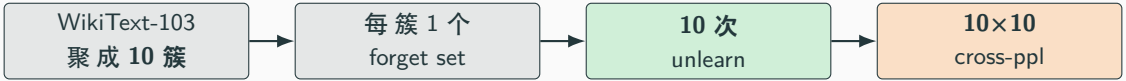


每个 ckpt 在每个簇上都评 PPL $\Rightarrow$ 10×10 矩阵

# L1 / L2 / L3 在 10×10 矩阵里的位置

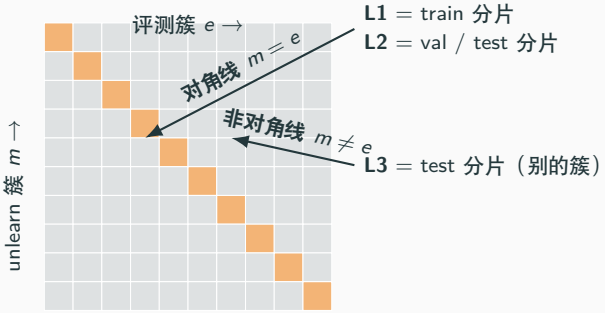

# 第一幕 · 数据证实三层 View

# 这一幕要说服你三件事

**C1** 三层**严格递减**（L1 > L2 > L3），不是乱分箱。

**C2** L3 **不是 0**：无关样本也真被波及。

**C3** profile **随 forget set 变化**，所以值得审计。

# C1 + C2：headline 数字

| | L1 forget | L2 locality | L3 spillover |
|---|---|---|---|
| geo-mean $r$ | **1.76×** | **1.29×** | **1.16×** |
| 被抬高（$> 1.1$）占比 | 95.6 % | 82.8 % | 61.6 % |

**C1 成立**：$1.76 > 1.29 > 1.16$

**C2 成立**：L3 仍有 61.6 % 样本被抬高

# C1 + C2：一图

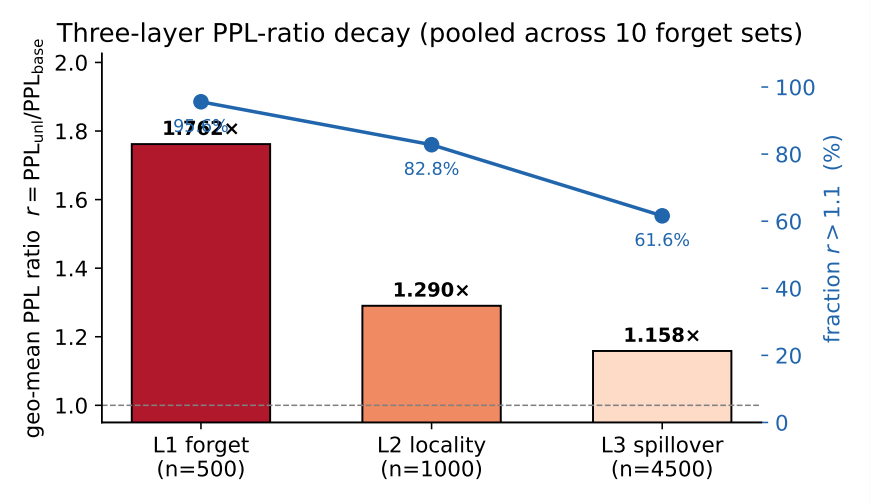


左轴：L1 > L2 > L3 ｜：L3 仍有 61.6 % 被抬高。

# C3：换个 forget set，副作用差多少？

| | L1 | L2 | L3 |
|---|---|---|---|
| 最温和（star） | 1.42 | 1.12 | 1.07 |
| 最严重（storm） | **2.44** | **1.78** | **1.25** |
| 极差比 | **1.72×** | 1.60× | 1.17× |

同一算法，换 forget set，L1 副作用差 **1.7×**。

⇒ profile 是 forget set 的函数，值得审计。

# C3：一图

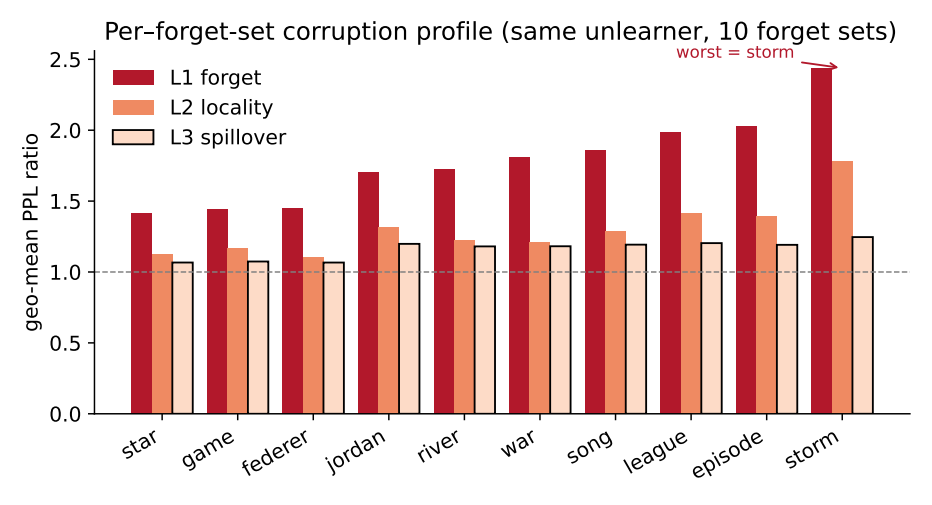


按 L1 升序；storm 三层同时最严重 ⇒ 稳健坏 forget set。

# 第二幕 · 与其每次 unlearn，不如审计

# 审计问题：输入是什么、输出是什么

不看 evaluation · 不跑 unlearn

12 维 = 方差 / 两两相似度 / centroid / 集中度（effective rank, isotropy）。
10 forget set 上 Leave-One-Out。

# 审计结果

| | L1 forget | L2 locality | L3 spillover |
|---|---|---|---|
| $R^2$ | **+0.44** | **+0.41** | +0.19 |
| 排序 Spearman $\rho$ | +0.62 | +0.62 | +0.61 |
| Top-1 命中 | ✓ storm | × | × |

## 三层排序相关 $\rho \approx$ **0.62**

L1 最严重的 forget set (`storm`) 被正确预测到。

$n = 10$，单观察点；$n \uparrow$、换 *unlearner* 的稳健性待验证。

# 审计散点：预测 vs 真实

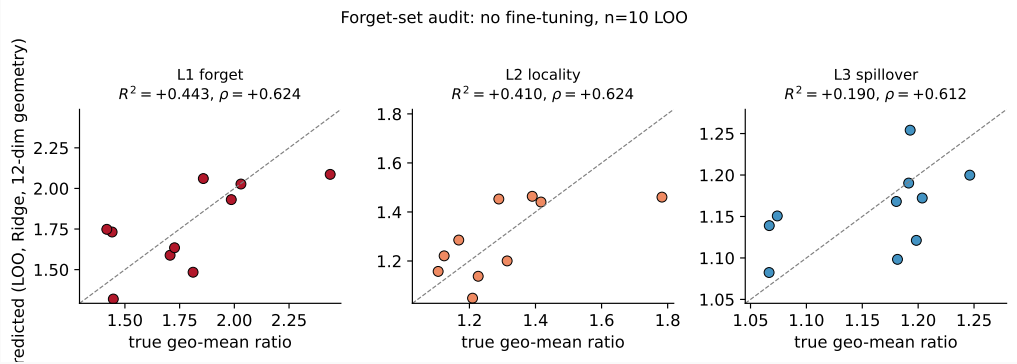


虚线 $y = x$；三层 $\rho \approx 0.62$；L3 幅度小、排序仍可用。

# 几何 vs 文本表面

| 特征 | 维度 | $R^2$ |
|---|---|---|
| 文本表面统计 | 261 | $+0.14$ |
| **纯几何** | **16** | $\mathbf{+0.36}$ |

特征少 $16\times$，$R^2$ 高 $2.5\times$

corruption 更像几何现象，而非文本难度现象。

# 诚实负结果：球覆盖不 work

试过：用 forget set 的半径圈 retain，看落入比例。

结果：与真实 L3 的相关 $\rho = -0.42$（**方向反了**）

原因：簇之间互相重叠，球太大 $\Rightarrow$ 几乎全覆盖。

改进：带符号投影 / mutual-reachability 距离。

# 讨论

# Related Work

## 相邻工作与我们的差别

| 相邻方向 | 我们的差别 |
|---|---|
| Data-first 鲁棒性 (Dang+ ACL'24) | 训练集特征 $\rightarrow$ 对抗 ASR $\Rightarrow$ 迁到 *unlearning corruption* |
| LLM unlearning 算法 | 我们固定 unlearner，分析数据依赖的副作用 |
| Influence / editing locality | model-centric $\rightarrow$ *data-centric* 三层风险 |

# Limitations

## 四个「单」

- 单 base model（Llama-3.1-8B-Instruct）
- 单 unlearner（GradAscent）
- 单 $n = 10$ forget sets（CI 较宽）
- 单指标 PPL（$\neq$ QA 准确率）

# Future Work

## 对应四个「单」的解法

1. $n$ : 10 $\rightarrow$ 100（100 triplet 已生成）
2. 加 NPO / GradDiff 验证审计器稳健
3. PPL $\rightarrow$ QA accuracy（`2.extract-qa/` 已就位）
4. *audit-driven* forget 选择：挑预测 L3 最低的 $\mathcal{D}_f$

# 论文定位

*A Three-Layer View of Knowledge Corruption in LLM Unlearning.*

**三个卖点**

1. 三层 view + L3 61.6 % $\Rightarrow$ spillover 不可忽略
2. benchmarking $\rightarrow$ **forget-set audit** 视角转换
3. 仅几何就能排序预测（$\rho \approx 0.62$）

**升档**：$n$=10 $\rightarrow$ 100 + 第二个 unlearner $\Rightarrow$ NeurIPS / ICML

**三层衰减，但不归零。**

$1.76\times \rightarrow 1.29\times \rightarrow 1.16\times$

**审计** $\rho \approx 0.62$，**无需 unlearn**。

# 附录—复现主结果

```
# 0. Unlearn 与 cross-ppl (已完成可跳过)
#     2.extract-ppl/wikitext_cross_metrics_detail.json

# 1. 第一幕: 三层 ground truth
cd 2.extract-ppl
python analyze_corruption.py          #  corruption_summary.json

# 2. 第二幕 A: per-sample 几何预测器
cd ../4.regression-predictor
python 3.corruption_from_geometry.py  #  geometry/geometry_results.json

# 3. 第二幕 B: forget-set 审计 (LOO, Part 1+2+3+3b)
python 4.audit_experiments.py         #  audit/audit_summary.json
```

# 附录—关键 artefact

| Artefact | 路径 |
|---|---|
| Cross-eval ppl 明细 | `2.extract-ppl/wikitext_cross_metrics_detail.json` |
| 三层 corruption 汇总 | `2.extract-ppl/corruption_summary.json` |
| 几何 per-sample 预测 | `4.regression-predictor/geometry/geometry_results.json` |
| 审计器 LOO 预测 | `4.regression-predictor/audit/audit_summary.json` |
| 每 forget set L1/L2/L3 | `audit/part1_corruption_profile.csv` |
| 审计特征表 | `audit/part2_forget_features.csv` |