From Three-Layer Corruption to Forget-Set Audit in LLM Unlearning

不跑 unlearn，只看 forget set 几何 $\Rightarrow$ 排序级副作用预警

Bo | `unlearning/`

Llama-3.1-8B-Instruct + GradAscent + WikiText-103 (HDBSCAN $\times$ 10)

定义

三层定义 + 量化指标

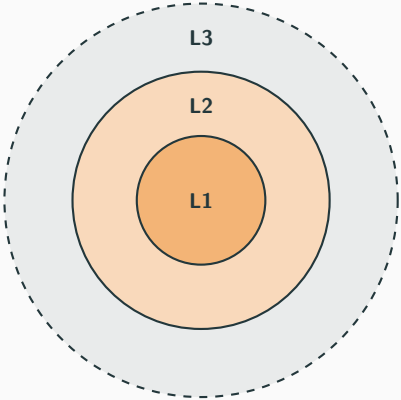

L1 想遗忘的
被 unlearn 那批样本

L2 连带忘的
同 cluster · 没训过

L3 不该忘却被波及
别的 cluster

$$r = \frac{\mathrm{PPL}_{\mathrm{unlearned}}}{\mathrm{PPL}_{\mathrm{base}}}$$

每层取几何均值
$\Rightarrow$ L1 / L2 / L3 各一个数

一句话贡献

Unlearning 的副作用沿语义距离**三层衰减，但不归零**。

L1 2.13× → L2 1.49× → L3 1.28×

且 80.3 % 的「无关」样本 PPL 也被抬高。

Llama-3.1-8B-Instruct · GradAscent · $n = 50$ forget sets (10 HDBSCAN clusters × 5).

一图看懂：三层 corruption + 几何排序

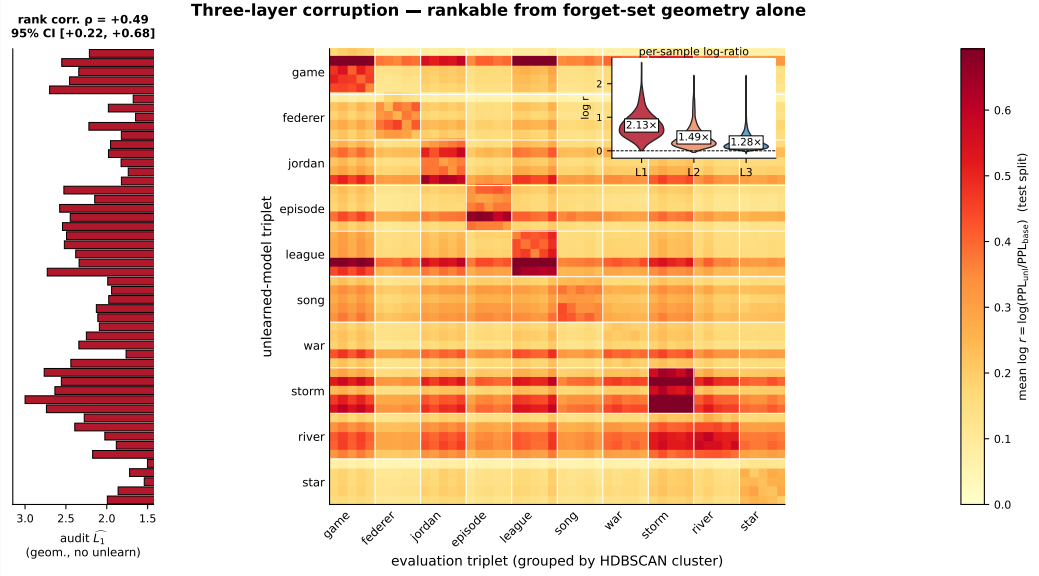

动机：一句话

换个 forget set，副作用能差 **近 4×**。

可每跑一个 unlearn 要数 GPU-hour。

能不能不 fine-tune，就预测副作用？

数据怎么来：四步

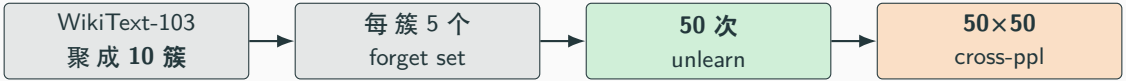

每个 ckpt 在每个 triplet 上都评 PPL $\Rightarrow$ 50×50 矩阵

L1 / L2 / L3 在 cross-matrix 里的位置

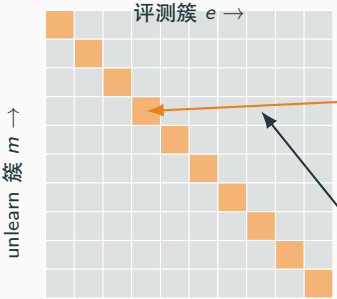

对角线（橙）

$m = e$

L1 = train

L2 = val / test

非对角线（灰）

$m \neq e$

L3 = test

第一幕 · 三层真的存在

这一幕要说服你三件事

C1 三层**严格递减**（L1 > L2 > L3），不是乱分箱。

C2 L3 **不是 0**：无关样本也真被波及。

C3 profile **随 forget set 变化**，所以值得审计。

C1 + C2：headline 数字

$$r = \frac{\mathrm{PPL}_{\mathrm{unlearned}}}{\mathrm{PPL}_{\mathrm{base}}} \quad \text{（PPL 被抬高几倍）} \qquad \text{geo-mean } r = \exp(\overline{\log r})$$

	L1 forget	L2 locality	L3 spillover
geo-mean r	**2.13×**	**1.49×**	**1.28×**
被抬高（> 1.1）占比	99.0 %	91.9 %	80.3 %

C1 成立：$2.13 > 1.49 > 1.28$

C2 成立：L3 仍有 80.3 % 样本被抬高

C1 + C2：一图

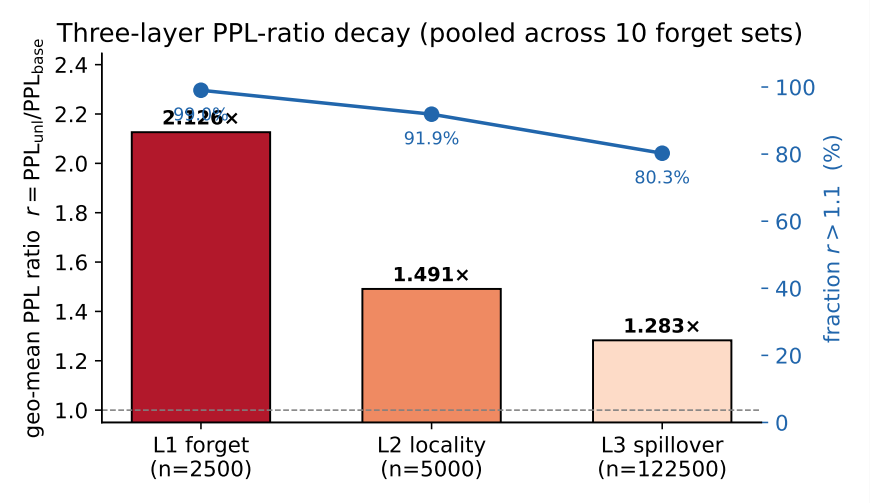

左轴：L1 > L2 > L3 ｜：L3 仍有 80.3 % 被抬高。

C3：换个 forget set，副作用差多少？

	L1	L2	L3
最温和（star 代表）	1.42	1.12	1.07
最严重（storm 簇 075）	**4.07**	**2.94**	**1.64**
极差比（$n = 50$）	**2.87×**	2.82×	1.54×

同一算法，换 forget set，L1 副作用差 **近 3×**。

$\Rightarrow$ profile 是 forget set 的函数，值得审计。

C3：一图

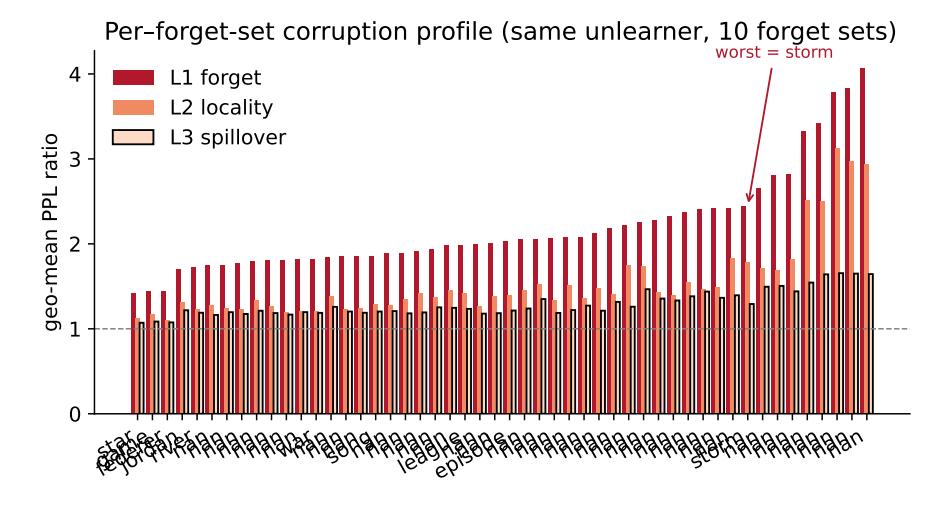

按 L1 升序（$n = 50$）；storm 簇 在所有三层上集中最严重 triplet。

第二幕 · 先审计，再决定

审计问题：输入是什么、输出是什么

不看 evaluation · 不跑 unlearn

12 维 = 方差 / 两两相似度 / centroid / 集中度（effective rank, isotropy）。
10 forget set 上 Leave-One-Out。

12 维几何特征是什么

类别	特征 (共 12)	回答什么
分散度	`emb_variance_mean / max` `pairwise_eucl_mean`	50 条文本在嵌入空间里铺得多开？
相似度	`pairwise_sim_mean / std / q90`	文本两两之间多相似？有多集中？
位置 / 规模	`centroid_norm` `emb_norm_mean / std`	forget set 在空间里离原点多远？

形状 / 集中度	`effective_rank`
	`isotropy`
	`spread_over_centroid`
		这团点云是"一根线"还是"一个球"？

全部只看 forget set 自己的 50 条 embedding

不看任何 evaluation 文本、不跑 unlearn。

审计结果

	L1 forget	L2 locality	L3 spillover
R^2 (audit / baseline -0.04)	**+0.22**	**+0.30**	+0.05
MAE (audit / baseline)	**0.40** / 0.43	**0.28** / 0.32	**0.12** / 0.12
排序 Spearman ρ	+0.49	+0.54	+0.30
95% CI ($n_{\text{boot}} = 10$k)	[+0.22, +0.68]	[+0.29, +0.72]	[−0.01, +0.55]
Top-1 命中	×	×	×

L1 / L2 排序显著（CI 排除 0）；L3 仍边缘

三层 R^2 全正、胜 LOO-mean baseline；$n = 100$ 可继续收紧 L3。

Held-out: LOO over 50 triplets (10 clusters × 5), Ridge $\alpha = 1$, 12-d forget geometry.

审计器的定位：预警器，不是替代品

	能做	不能做
排序	谁比谁严重 (L1/L2 $\rho \approx 0.49$–0.54)	绝对数值
粗筛	红 / 黄 / 绿三档预警	给 unlearn 打分
省算力	1 秒 vs. 数 GPU-hour	省掉最终 unlearn

审计器 = 便宜的粗筛预警器

用法：100 个候选 → 审计排序 → 真跑 top-k 验证
最终效果仍以真跑 unlearn 为准。

审计散点：预测 vs 真实

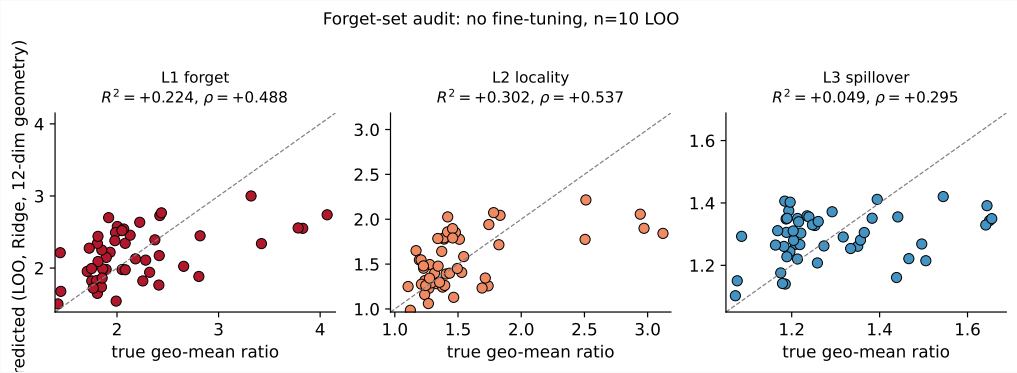

虚线 $y = x$；L1/L2 $\rho \approx 0.49$–0.54；L3 $\rho = 0.30$ 边缘。

几何 vs 文本表面

特征	维度	R^2
文本表面统计	261	$+0.14$
纯几何	**16**	$\mathbf{+0.36}$

特征少 $16\times$，R^2 高 $2.5\times$

corruption 更像几何现象，而非文本难度现象。

诚实负结果：球覆盖不 work

试过：用 forget set 的半径圈 retain，看落入比例。

结果：与真实 L3 的相关 $\rho = -0.27$（**方向反了**）

原因：簇之间互相重叠，球太大 $\Rightarrow$ 几乎全覆盖。

改进：带符号投影 / mutual-reachability 距离。

讨论

Related Work

相邻工作与我们的差别

相邻方向	我们的差别
Data-first 鲁棒性 (Dang+ ACL'24)	训练集特征 $\rightarrow$ 对抗 ASR $\Rightarrow$ 迁到 *unlearning corruption*
LLM unlearning 算法	我们固定 unlearner，分析数据依赖的副作用
Influence / editing locality	model-centric $\rightarrow$ *data-centric* 三层风险

Limitations

四个「单」

- 单 base model（Llama-3.1-8B-Instruct）
- 单 unlearner（GradAscent）
- $n = 50$ forget sets（L1/L2 CI 已显著，L3 仍边缘）
- 单指标 PPL（$\neq$ QA 准确率）

Future Work

对应四个「单」的解法

1. n : 50 $\rightarrow$ 100（100 triplet 已全部 unlearn，待扩 cross-eval）
2. 加 NPO / GradDiff 验证审计器稳健
3. PPL $\rightarrow$ QA accuracy（`2.extract-qa/` 已就位）
4. *audit-driven* forget 选择：挑预测 L3 最低的 $\mathcal{D}_f$

论文定位

From Three-Layer Corruption to Forget-Set Audit in LLM Unlearning.

三个卖点

1. 三层 view + L3 80.3 % $\Rightarrow$ spillover 不可忽略
2. benchmarking $\rightarrow$ **forget-set audit** 视角转换
3. 仅几何就能排序预测（L1/L2 $\rho \approx 0.49$–0.54，CI 显著排除 0）

升档：n=50 $\rightarrow$ 100 + 第二个 unlearner $\Rightarrow$ NeurIPS / ICML

三层衰减，但不归零。

2.13× → 1.49× → 1.28×

审计 L1/L2 $\rho \approx 0.49$–0.54 **（CI 显著），无需 unlearn。**

附录—复现主结果

```
# 0. Unlearn 与 cross-ppl (已完成可跳过)
#     2.extract-ppl/wikitext_cross_metrics_detail.json

# 1. 第一幕: 三层 ground truth
cd 2.extract-ppl
python analyze_corruption.py          #  corruption_summary.json

# 2. 第二幕 A: per-sample 几何预测器
cd ../4.regression-predictor
python 3.corruption_from_geometry.py  #  geometry/geometry_results.json

# 3. 第二幕 B: forget-set 审计 (LOO, Part 1+2+3+3b)
python 4.audit_experiments.py         #  audit/audit_summary.json
```

附录—关键 artefact

产物	路径
三层 corruption	`2.extract-ppl/corruption_summary.json`
审计 LOO 预测	`4.regression-predictor/audit/audit_summary.json`
每 forget set profile	`audit/part1_corruption_profile.csv`
审计特征	`audit/part2_forget_features.csv`