Three-Layer View of Knowledge Corruption in LLM Unlearning

为什么要审计 forget set，而不是每次都 unlearn

Bo | `unlearning/`

Llama-3.1-8B-Instruct + GradAscent + WikiText-103 (HDBSCAN $\times$ 10)

一句话贡献（初步）

在当前设置下，LLM unlearning 的 ppl 副作用沿语义距离呈三层衰减：

L1 forget 1.76× → L2 locality 1.29× → L3 spillover 1.16×

但 L3 并未归零（**61.6 %** 跨簇样本 surprisal 上升）。

- 10 个 forget set 上 L1 差 **1.7**× ⇒ 提示单 forget-set benchmark 稳定性不足。
- 用 **12 维 forget-set 内禀几何**、不跑 *unlearn*，LOO Spearman $\rho \approx$ **0.62** 预测三层风险。
- L1 层 top-1 预测与真实排序吻合（$n = 10$，单观察点）⇒ *forget-set* 审计 的 proof-of-concept。

所有结论均基于：单 *base model*（*Llama-3.1-8B-Instruct*）、单 *unlearner*（*GradAscent*）、$n = 10$ 个 *forget set*。

动机与定义

动机：unlearning 贵，副作用还反直觉

痛点

- Fine-tune 8B + 跨评测 ⇒ 数 GPU-hour / forget-set。
- 同算法在不同 forget set 上副作用差 **1.7×**。
- 现有 unlearning 论文几乎只用 一个 forget set 报数字。

研究问题

给候选 forget set，不 *fine-tune* 就预测它的 L1 / L2 / L3 corruption profile。

把 unlearning 从”**每次都跑**”改为”**先审计、再决定**”。

三层 Corruption View

对 base 模型 f 与 $\mathcal{D}_f$ 上 GradAscent 后的 $f_{\mathcal{D}_f}$:

$$r(f, \mathcal{D}_f, x) = \frac{\mathrm{PPL}(f_{\mathcal{D}_f}, x)}{\mathrm{PPL}(f, x)}.$$

层	x 与 $\mathcal{D}_f$ 的关系	直观含义
L1 forget	x 就是 $\mathcal{D}_f$ 的 train 分片	故意遗忘强度
L2 locality	x 来自同簇 retain/test	局部附带损伤
L3 spillover	x 来自另一簇	跨簇知识污染

Measurement Pipeline

WikiText-103
HDBSCAN → **10 语义簇**

→

每簇采 1 triplet
= 3 splits × 50 文本

→

10 个 GradAscent
unlearn ckpt

→

10×10 cross-matrix
per-sample ppl

矩阵位置		分片	用作
diagonal	$m = e$	`train` (50)	**L1** forget ($n = 500$)
diagonal	$m = e$	`validation` + `test` (100)	**L2** locality ($n = 1\,000$)
off-diagonal	$m \neq e$	`test` (50)	**L3** spillover ($n = 4\,500$)

Triplet = (`train`, `validation`, `test`) 三分片均来自同一 语义簇、互不重叠；每分片 50 文本。监督信号 $= \log r$。

第一幕 · 数据证实三层 View

这一幕要验证的三个论断

若 § 定义中的三层切分真抓住了 corruption 结构，数据应同时满足：

C1 单调性 r 随语义距离 L1 $\to$ L2 $\to$ L3 递减。
否则分层只是任意分箱，不是有序结构。

C2 非零溢出 L3 几何均值 > 1 且非零率可观。
否则跨簇污染只是噪声，框架退化为 locality 分析。

C3 forget-set 依赖 三层 profile 在 forget set 间显著不同。
否则三层只是算法常数，无审计可言（§ 第二幕失去动机）。

接下来两帧分别给出 **C1 + C2** 与 **C3** 的证据。

C1 + C2：层级 headline（全池样本）

Layer	n	geo-mean r	$> 1.1\times$	$> 2\times$
L1 forget	500	**1.762**×	95.6 %	33.2 %
L2 locality	1 000	**1.290**×	82.8 %	3.4 %
L3 spillover	4 500	**1.158**×	61.6 %	0.0 %

- **C1 成立**：1.762 → 1.290 → 1.158 严格单调；L2 保留 L1 损伤 **38 %**，L3 保留 **21 %**。
- **C2 成立**：L3 geo-mean = 1.158×、61.6 % 跨簇样本 surprisal 真的上升 ⇒ 溢出不可忽略。
- 消歧参照：self (同簇 test) 1.291× vs. cross 1.158×，locality multiplier 仅 **1.114**× —— L2 只比 L3 高 ∼11 %，局部性存在但比常见直觉弱。

C3：三层 profile 随 forget set 而变（差 1.7×）

forget set	簇	L1	L2	L3_out	
triplet_091	star	1.42	1.12	1.07	最温和
triplet_001	game	1.44	1.17	1.07	
triplet_011	federer	1.45	1.11	1.07	
triplet_021	jordan	1.71	1.31	1.20	
triplet_081	river	1.73	1.23	1.18	
triplet_061	war	1.81	1.21	1.18	
triplet_051	song	1.86	1.29	1.19	
triplet_041	league	1.99	1.42	1.20	
triplet_031	episode	2.03	1.39	1.19	
triplet_071	storm	**2.44**	**1.78**	**1.25**	最严重

- **C3 成立**：L1 跨 forget set 差 **1.72**×、L2 差 1.60×、L3_out 差 1.17× ——profile 是 forget set 的函数，不是算法常数。
- 嵌入紧凑度（低 emb variance）与 L2 的 Spearman $\rho = 0.50$ ($n = 10$，CI 较宽，提示性证据）——已暗示几何可预测 *corruption*（第二幕将正式化）。
- 方法学含义：仅用单 forget set 给 unlearner 打分会显著低估评分方差 ⇒ suggests benchmark instability，而非”系统性误报”。

小结：C1 + C2 说明三层是有序且 *L3* 非平凡的结构；C3 说明 profile 因 forget set 而异 ⇒ **预测 profile 是良定义问题**（→ 第二幕）。

第二幕 · 与其每次 unlearn，不如审计

审计问题

Forget-Set Audit
给候选 $\mathcal{D}_f$ 与 base 模型，不跑 *fine-tune*，输出 L1 / L2 / L3 三个风险分数。

审计特征（12 维，纯 forget-set 内禀几何）

- 方差：`emb_variance_{mean,max}`
- 两两：`pairwise_sim_{mean,std,q90}`, `pairwise_eucl_mean`
- Centroid / norm：`centroid_norm`, `emb_norm_{mean,std}`
- 集中度：`effective_rank`, `isotropy`, `spread_over_centroid`

• 不看任何 evaluation text • 不跑任何 unlearn • 10 forget set 上 Leave-One-Out + Ridge。

审计结果：回归 + 排序

回归（LOO over 10 forget sets）

审计目标	R^2	Spearman ρ	Pearson r
L1 forget	**+0.443**	+0.624	+0.684
L2 locality	**+0.410**	+0.624	+0.658
L3 spillover	+0.190	**+0.612**	+0.512

排序（predicted rank vs. true rank）

Layer	Spearman ρ	Top-1 命中	Top-3 重合
L1 forget	+0.624	✓ storm	2 / 3
L2 locality	+0.624	×	2 / 3
L3 spillover	+0.612	×	1 / 3

L1 层 top-1 与真实排序一致（triplet_071 storm，单观察点，$n = 10$）。初步证据支持审计器作为 排序 / 筛选工具 的可行性；是否对更大 n、其他 unlearner、其他 base model 稳健，尚需验证。

Per-sample 对照：几何 $\gg$ 文本表面

设定	特征数	LOGO R^2
旧：261 维表格（含 per-text 表面统计）	261	+0.142
新：16 维纯几何（forget + target forget）	**16**	**+0.362** (GBM)
仅限 L3 跨簇样本（纯 spillover）	16	+0.247 (RF)

解读（谨慎）
在当前设置下，几何特征以约 6 % 的特征数带来 2.5× 的 R^2。这支持 "corruption 与 forget-set 几何比与文本表面统计更相关" 的假设；在单 base model、单 unlearner、$n = 10$ 下，尚不足以断言"corruption 是几何现象而非文本难度现象"。

诚实负结果：Naive retain-coverage 不 work

把 forget set 的 p95 内部 euclidean 当"高风险半径"，测 retain 落入比例：

- 9 / 10 个 forget set 的 mean coverage ≈ 1.0 ——半径太大，区分度归零。
- 与真实 L3 spillover 的相关：$\rho = -0.42$（方向反了）。

原因：HDBSCAN 簇在 384 维原空间里互相重叠，p95 半径 $>$ 簇间距。

改进方向

1. 到 centroid 的带符号投影，单尾切片而非球覆盖；
2. HDBSCAN 原生 mutual-reachability 距离；
3. 直接把 L3 predictor 当 calibrated per-text risk score。

讨论

Related Work（占位，待程序化补全）

Data-first 鲁棒性预测 Dang et al. (ACL 2024): 13 维训练集特征 → 对抗 ASR。我们把方法论迁到 生成式 *unlearning* 的 *corruption profile* 审计。

LLM unlearning GradAscent / NPO / GradDiff / TOFU 由 `open-unlearning` 提供；我们固定 *unlearner*，分析其 data-conditioned 副作用。

Influence / editing locality Model-centric 的局部性已被广研；我们用 10×10 cross-ppl 矩阵把它变成可度量的三层风险。

Limitations

- $n = 10$ **clusters** ——审计 $\rho = 0.62$ 置信区间较宽；100 triplet 全跑可升级到 $n = 100$。
- **单 unlearner** ——L1/L2/L3 对 NPO / GradDiff 的稳健性待测。
- **单 base model** ——Llama-3.1-8B-Instruct；其他规模 / 家族未测。
- **ppl** $\neq$ **fact** ——L3 的 61.6 % 样本是否对应 QA 准确率下降？`2.extract-qa/` 管线已就位。
- **Naive coverage 失败**——§5.6 需要更细的几何风险度量。

Future Work

1. **Scale-up**：100 triplet 全跑 unlearn $\Rightarrow n = 100$。
2. **跨 unlearner**：加 NPO / GradDiff，审计器须稳健。
3. **更好的 coverage**：方向投影 / mutual-reachability。
4. **Audit-driven forget 选择**：在 retain 约束下挑 predicted L3 最小的 $\mathcal{D}_f$，真跑 unlearn 验证。
5. **QA 层面**：target 换成 QA accuracy。

论文定位

- **Title（工作名）**：*A Three-Layer View of Knowledge Corruption in LLM Unlearning, and Why You Should Audit Before You Forget.*
- **Venue**：COLM 2025 / ACL short / EMNLP findings ——empirical + analysis + methodological 三位一体。
- **卖点（以当前证据强度措辞）**：(1) 三层 view + 61.6 % 的 L3 spillover 提示 *spillover* 不可忽略；(2) 把 unlearning benchmarking 重构为 *forget-set audit*；(3) 仅 forget-set 几何即可做排序级风险预测（LOO $\rho \approx 0.62$，L1 top-1 匹配为单观察点）。
- **升档**：补到 $n = 100$ + 第二个 unlearner $\Rightarrow$ NeurIPS / ICML。

三层衰减 · spillover 不可忽略 · 无需 unlearn 的审计

1.76× → 1.29× → 1.16× | 61.6 % | LOO $\rho \approx 0.62$ | L1 top-1 吻合 (单点)

单 *base model* · 单 *unlearner* · $n = 10$ *forget sets* — 待更大 n 复证。

附录—复现主结果

1. 第一幕：三层 ground truth cd 2.extract-ppl python analyze$_{c}orruption.pycorruption_{s}ummary.json$
2. 第二幕 A：per-sample 几何预测器 cd ../4.regression-predictor python 3.corruption$_{f}rom_{g}eometry.pygeor$
3. 第二幕 B：forget-set 审计（LOO，Part 1+2+3+3b） python
4.audit$_{e}xperiments.pyaudit/audit_{s}ummary.json$

附录—关键 artefact

Artefact	路径
Cross-eval ppl 明细	`2.extract-ppl/wikitext_cross_metrics_detail.json`
三层 corruption 汇总	`2.extract-ppl/corruption_summary.json`
几何 per-sample 预测	`4.regression-predictor/geometry/geometry_results.json`
审计器 LOO 预测	`4.regression-predictor/audit/audit_summary.json`
每 forget set L1/L2/L3	`audit/part1_corruption_profile.csv`
审计特征表	`audit/part2_forget_features.csv`