Three-Layer View of Knowledge Corruption in LLM Unlearning

为什么要审计 forget set，而不是每次都 unlearn

Bo | `unlearning/`

Llama-3.1-8B-Instruct + GradAscent + WikiText-103 (HDBSCAN $\times$ 10)

一句话贡献

Unlearning 的副作用沿语义距离**三层衰减，但不归零**。

L1 1.76× → L2 1.29× → L3 1.16×

且 61.6 % 的「无关」样本 PPL 也被抬高。

Llama-3.1-8B-Instruct · GradAscent · $n = 10$ forget sets.

定义

动机：一句话

换个 forget set，副作用能差 **1.7×**。

可每跑一个 unlearn 要数 GPU-hour。

能不能不 fine-tune，就预测副作用？

三层是什么：一张同心圆图

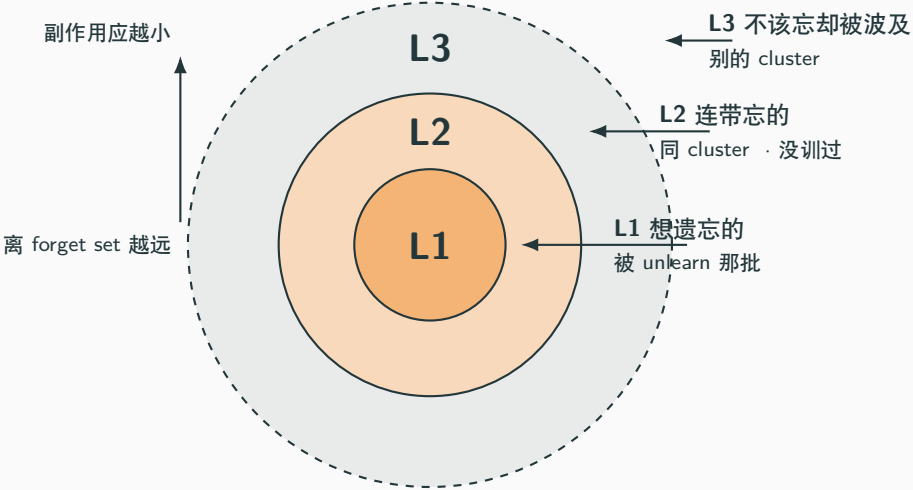

怎么量化：一个比值

$$r = \frac{\mathrm{PPL}_{\mathrm{unlearned}}}{\mathrm{PPL}_{\mathrm{base}}}$$

$r = 1.8 \Rightarrow$ **这条样本的 PPL 被抬高到 1.8 倍**。

每一层取几何均值 $\Rightarrow$ 得到 L1 / L2 / L3 的一个数。

数据怎么来：四步

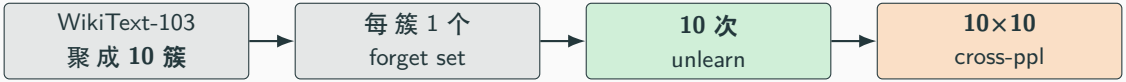

每个 ckpt 在每个簇上都评 PPL $\Rightarrow$ 10×10 矩阵

L1 / L2 / L3 在 10×10 矩阵里的位置

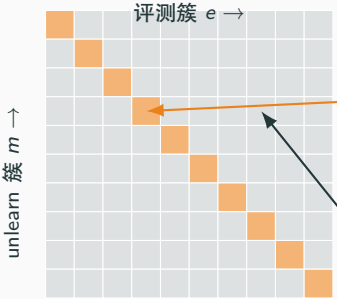

对角线（橙）

$m = e$

L1 = train

L2 = val / test

非对角线（灰）

$m \neq e$

L3 = test

第一幕 · 三层真的存在

这一幕要说服你三件事

C1 三层**严格递减**（L1 > L2 > L3），不是乱分箱。

C2 L3 **不是 0**：无关样本也真被波及。

C3 profile **随 forget set 变化**，所以值得审计。

C1 + C2：headline 数字

	L1 forget	L2 locality	L3 spillover
geo-mean r	**1.76×**	**1.29×**	**1.16×**
被抬高（> 1.1）占比	95.6 %	82.8 %	61.6 %

C1 成立：$1.76 > 1.29 > 1.16$

C2 成立：L3 仍有 61.6 % 样本被抬高

C1 + C2：一图

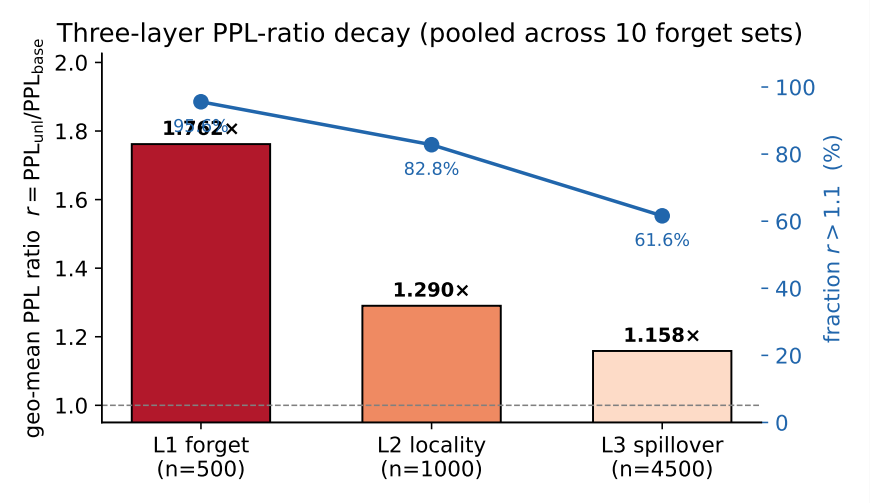

左轴：L1 > L2 > L3 ｜：L3 仍有 61.6 % 被抬高。

C3：换个 forget set，副作用差多少？

	L1	L2	L3
最温和（star）	1.42	1.12	1.07
最严重（storm）	**2.44**	**1.78**	**1.25**
极差比	**1.72×**	1.60×	1.17×

同一算法，换 forget set，L1 副作用差 **1.7×**。

⇒ profile 是 forget set 的函数，值得审计。

C3：一图

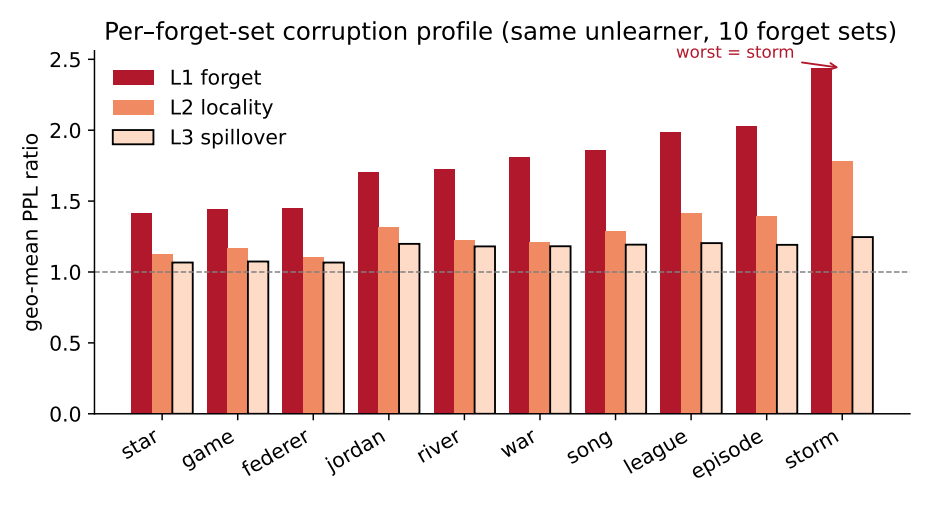

按 L1 升序；storm 三层同时最严重 ⇒ 稳健坏 forget set。

第二幕 · 先审计，再决定

审计问题：输入是什么、输出是什么

不看 evaluation · 不跑 unlearn

12 维 = 方差 / 两两相似度 / centroid / 集中度（effective rank, isotropy）。
10 forget set 上 Leave-One-Out。

审计结果

	L1 forget	L2 locality	L3 spillover
R^2	**+0.44**	**+0.41**	+0.19
排序 Spearman ρ	+0.62	+0.62	+0.61
Top-1 命中	✓ storm	×	×

三层排序相关 $\rho \approx$ **0.62**

L1 最严重的 forget set (`storm`) 被正确预测到。

$n = 10$，单观察点；$n \uparrow$、换 *unlearner* 的稳健性待验证。

审计散点：预测 vs 真实

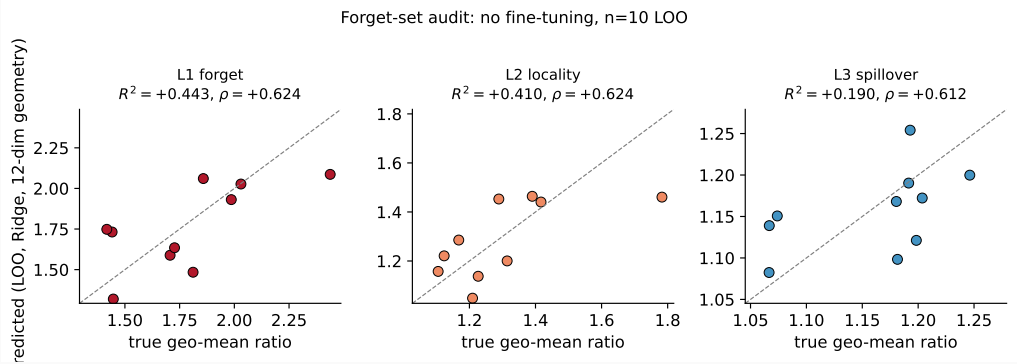

虚线 $y = x$；三层 $\rho \approx 0.62$；L3 幅度小、排序仍可用。

几何 vs 文本表面

特征	维度	R^2
文本表面统计	261	$+0.14$
纯几何	**16**	$\mathbf{+0.36}$

特征少 $16\times$，R^2 高 $2.5\times$

corruption 更像几何现象，而非文本难度现象。

诚实负结果：球覆盖不 work

试过：用 forget set 的半径圈 retain，看落入比例。

结果：与真实 L3 的相关 $\rho = -0.42$（**方向反了**）

原因：簇之间互相重叠，球太大 $\Rightarrow$ 几乎全覆盖。

改进：带符号投影 / mutual-reachability 距离。

讨论

Related Work

相邻工作与我们的差别

相邻方向	我们的差别
Data-first 鲁棒性 (Dang+ ACL'24)	训练集特征 $\rightarrow$ 对抗 ASR $\Rightarrow$ 迁到 *unlearning corruption*
LLM unlearning 算法	我们固定 unlearner，分析数据依赖的副作用
Influence / editing locality	model-centric $\rightarrow$ *data-centric* 三层风险

Limitations

四个「单」

- 单 base model（Llama-3.1-8B-Instruct）
- 单 unlearner（GradAscent）
- 单 $n = 10$ forget sets（CI 较宽）
- 单指标 PPL（$\neq$ QA 准确率）

Future Work

对应四个「单」的解法

1. n : 10 $\rightarrow$ 100（100 triplet 已生成）
2. 加 NPO / GradDiff 验证审计器稳健
3. PPL $\rightarrow$ QA accuracy（`2.extract-qa/` 已就位）
4. *audit-driven* forget 选择：挑预测 L3 最低的 $\mathcal{D}_f$

论文定位

A Three-Layer View of Knowledge Corruption in LLM Unlearning.

三个卖点

1. 三层 view + L3 61.6 % $\Rightarrow$ spillover 不可忽略
2. benchmarking $\rightarrow$ **forget-set audit** 视角转换
3. 仅几何就能排序预测（$\rho \approx 0.62$）

升档：n=10 $\rightarrow$ 100 + 第二个 unlearner $\Rightarrow$ NeurIPS / ICML

三层衰减，但不归零。

$1.76\times \rightarrow 1.29\times \rightarrow 1.16\times$

审计 $\rho \approx 0.62$，**无需 unlearn**。

附录—复现主结果

```
# 0. Unlearn 与 cross-ppl (已完成可跳过)
#     2.extract-ppl/wikitext_cross_metrics_detail.json

# 1. 第一幕: 三层 ground truth
cd 2.extract-ppl
python analyze_corruption.py          #  corruption_summary.json

# 2. 第二幕 A: per-sample 几何预测器
cd ../4.regression-predictor
python 3.corruption_from_geometry.py  #  geometry/geometry_results.json

# 3. 第二幕 B: forget-set 审计 (LOO, Part 1+2+3+3b)
python 4.audit_experiments.py         #  audit/audit_summary.json
```

附录—关键 artefact

产物	路径
三层 corruption	`2.extract-ppl/corruption_summary.json`
审计 LOO 预测	`4.regression-predictor/audit/audit_summary.json`
每 forget set profile	`audit/part1_corruption_profile.csv`
审计特征	`audit/part2_forget_features.csv`